Universidade Estadual de Campinas - Instituto de Computação (IC/Unicamp)

Disciplina Aprendizado de Máquina (MO444)

Professor: Jacques Wainer, PhD.

Atividade 2, 4 de outubro de 2016

Aluno: Luiz Alberto Ferreira Gomes RA:007275

Questão 1:

Qual a acurácia média (na validação de fora)

Solução:

A acurácia media calculada e exibida na linha 99 do script em R (ver Anexo I) foi de 0.8696912.

Questão 2:

Quais são os valores de C e gamma a serem utilizados no classificador final(fazer o 3-fold no conjunto todo)

Solução:

O valores de C e gamma obtidos pelo script em R (ver Anexo I), após o *cross-validation*, apresentados na linha 100, foram respectivamente 2^2 e 2^{-15} . A acurácia utilizando esses hiperparâmetros, após do 3-fold sobre todo o conjunto de dados, foi de 0.864665.

Anexo I: Script fonte em R

```
1 #
2 # Description:
       Solutions for activity 2 (MO444)
3 #
4 #
     Version: 1.0
6 #
7 #
    Author:
      Luiz Alberto, gomes.luiz@gmail.com
8 #
9 #
10 # History:
       Sep 26th,
                    2016 started
11 #
       {\rm Sep}\ 27{\rm th}\;,
                    2016 updated
12 #
13 #
       Sep 28th,
                    2016
                          updated
       Sep 29th,
14 #
                    2016
                          updated.
      Sep 30th,
                    2016
                          updated.
15 #
16 #
17 # To do:
18 #
19 # -
20 if (!require(caret))
    install.packages('caret')
22 if (!require(e1071))
    install.packages('e1071')
23
25 library('caret')
26 library('e1071')
28 # initializes execution environment.
29 rm(list=ls())
30 setwd('~/Workspace/doutorado/disciplinas/mo444b/atividades/2')
31
32 \# reads raw data from file.
33 raw.data <- read.csv(file = './data/data1.csv', header = TRUE, sep = ',')
34
35 \#  selects 80\%  of raw data for train.
36 raw.data.train <- raw.data[trunc(nrow(raw.data) * 0.8),]
38 # initializes cost and gamma grid.
39 grid.costs <-c(2 ** -5 , 2 ** -2 , 2 ** 0 , 2 ** 2, 2 ** 5)
```

Universidade Estadual de Campinas - Instituto de Computação (IC/Unicamp)

Disciplina Aprendizado de Máquina (MO444)

Professor: Jacques Wainer, PhD. Atividade 2, 4 de outubro de 2016 Aluno: Luiz Alberto Ferreira Gomes RA:007275

```
40 grid.gammas <- c(2 ** -15, 2 ** -10, 2 ** -5, 2 ** 0, 2 ** 5)
42 # performs the external cross-validation using 5-folds methods.
43 external.folds <- createFolds (raw.data.train, k = 5, returnTrain = TRUE)
44 external.final.accuracy <- 0
45 for (e in external.folds) {
     external.train.data <- raw.data[e, ]
     external.test.data <- raw.data[-e, ]
47
48
     # performs the internal cross-validation using 3-folds methods.
49
     internal.folds <- createFolds(external.train.data, k = 3, returnTrain = TRUE)
50
     internal.max.accuracy <- 0
51
     for (i in internal.folds) {
52
       internal.train.data <- external.train.data[i ,]
internal.test.data <- external.train.data[-i ,]</pre>
53
54
55
56
       # searchs in hyperparameters grid for the maximum accuracy.
       for (cost.pos in 1:5) {
57
          for (gamma.pos in 1:5) {
58
59
            # uses hyperparameters in grid to train model.
60
            internal.svm.fit <-
61
              svm(clase
                   data = internal.train.data,
63
64
                   cost = grid.costs[cost.pos]
                   gama = grid.gammas[gamma.pos],
65
                   kernel="radial")
66
67
            # predicts with test data with internal svm model.
68
            internal.svm.probs \leftarrow predict(internal.svm.fit, internal.test.data) internal.svm.pred \leftarrow ifelse(internal.svm.probs > 0.5, 1, 0)
69
70
            internal.sym.error <- mean(internal.sym.pred != internal.test.data$clase)</pre>
71
            internal.\,accuracy\,<\!\!-1\,-\,internal.svm.\,error
72
73
            if (internal.accuracy > internal.max.accuracy){
74
              internal.max.accuracy <- internal.accuracy
75
              h.max.cost <- grid.costs[cost.pos]
76
              h.max.gamma <- grid.gammas[gamma.pos]
77
            }
          }
79
       }
80
81
     # uses hyperparameters to train model
82
83
     external.svm.fit <-
       svm(clase ~ .,
84
            data = external.train.data,
85
86
            cost = h.max.cost,
            gama = h.max.gamma,
87
            kernel="radial")
88
     # predicts with test data with external svm model.
90
     external.svm.probs <- predict(external.svm.fit, external.test.data)
91
     external.svm.pred <- ifelse (external.svm.probs > 0.5, 1, 0)
external.svm.error <- mean(external.svm.pred != external.test.data$clase)
92
93
     external.accuracy
                           <- 1 - external.svm.error
94
95
     external.final.accuracy <- external.accuracy + external.final.accuracy
96
97 }
98
99 cat('accuracy after cross validation = ', external.final.accuracy/5, '\n')
100 cat(' cost and gama to use on classifier = ', h.max.cost,' and ', h.max.gamma,
102 # performs the 3-folds method on all data.
103 final.folds <- createFolds(raw.data, k = 3, returnTrain = TRUE)
104 final.accuracy <- 0
105 for (e in final.folds) {
```

Universidade Estadual de Campinas - Instituto de Computação (IC/Unicamp) Disciplina Aprendizado de Máquina (MO444)

Professor: Jacques Wainer, PhD. Atividade 2, 4 de outubro de 2016 Aluno: Luiz Alberto Ferreira Gomes RA:007275

```
final.train.data <- raw.data[e, ]
106
107
      final.test.data \leftarrow raw.data[-e,]
108
      # applies hyperparameters classifier on all data
109
      final.svm.fit <-
110
        svm(clase
111
              data = final.train.data,
112
              cost = h.max.cost,
113
              gama = h.max.gamma,
114
              kernel="radial")
115
116
      final.svm.probs <- predict(final.svm.fit , final.test.data)</pre>
117
118
      \begin{array}{lll} \mbox{final.svm.pred} & <- \mbox{ ifelse(final.svm.probs} > 0.5\,,\ 1,\ 0) \\ \mbox{final.svm.error} & <- \mbox{ mean(final.svm.pred} \ != \mbox{ final.test.data\$clase)} \end{array}
119
120
      final.accuracy.local <- 1 - final.svm.error
121
122
123
      final.accuracy <- final.accuracy.local + final.accuracy
124 }
125 cat('classifier accuracy in all data set = ', final.accuracy/3, '\n')
```